

Fundamentos Matemáticos en Visión Artificial: Difusión, Flow Matching y Transformers

Este documento recopila, corrige y expande los conceptos matemáticos expuestos en material divulgativo, adaptándolos para el desarrollo de sistemas de visión artificial modernos. Se divide en los pilares fundamentales de generación y análisis visual, actualizados con el estado del arte a mediados de 2026.

Parte 1: Generación de Imágenes (LDMs y Flow Matching)

Las ecuaciones compartidas originalmente describen un **Modelo de Difusión Latente (LDM)** (como las primeras versiones de Stable Diffusion). Si bien dominaron la generación de imágenes, el estado del arte ha evolucionado hacia arquitecturas híbridas y nuevos paradigmas.

1.1 Modelos de Difusión Latente (LDMs Clásicos)

1. Compresión Perceptual (Autoencoder):

- $z = \mathcal{E}(x)$ (Codificación)
- $x = \mathcal{D}(z_0)$ (Decodificación)
- **Implicancia:** Trabajar en píxeles (x) es prohibitivo. La imagen se comprime en un espacio latente z . Innovaciones recientes (2025) han introducido pérdidas perceptuales en el espacio latente (LPL) utilizando las características internas del decodificador para generar imágenes mucho más nítidas y realistas.

2. Condicionamiento (Cross-Attention):

- $c = \tau_\theta(\text{prompt})$

3. Proceso de Difusión (Adición y Predicción de Ruido):

- $z_t = \sqrt{\bar{\alpha}_t} z_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$ (Proceso Directo)
- $\mathcal{L} = ||\epsilon - \epsilon_\theta(z_t, t, c)||^2$ (Función de Pérdida)
- **Implicancia:** El modelo aprende a estimar el ruido iterativamente.

4. Control de Generación (Classifier-Free Guidance):

- $\tilde{\epsilon} = \epsilon_\emptyset + w(\epsilon_c - \epsilon_\emptyset)$

1.2 El Cambio de Paradigma: Flow Matching (2024-2026)

A partir de 2024 y consolidándose en 2025/2026, **Flow Matching (FM)** ha comenzado a

reemplazar a la difusión pura en la generación de vanguardia debido a su eficiencia superior.

- **El Problema de la Difusión:** La difusión sigue una trayectoria curva y estocástica de ruido a imagen, requiriendo cientos de pasos de inferencia (costoso en GPUs).
- **La Solución de Flow Matching:** En lugar de predecir el ruido paso a paso, FM aprende un campo vectorial continuo (una trayectoria lineal "rectificada") que conecta el ruido con la imagen directamente. Esto permite generar imágenes de calidad equivalente en una fracción de los pasos.
- **Convergencia (Diff2Flow):** Investigaciones recientes (como *Diff2Flow* en CVPR 2025) han demostrado que la Difusión y Flow Matching son equivalentes bajo ciertas condiciones. Hoy en día, es común entrenar un modelo base con difusión (lento pero robusto) y luego "destilarlo" o alinearlos (re-escalando pasos de tiempo y campos de velocidad) hacia un modelo Flow Matching (rápido en inferencia).

Citas Académicas (Generación de Vanguardia):

- **LDM Clásico:** Rombach, R., et al. (2022). *High-Resolution Image Synthesis with Latent Diffusion Models*. CVPR.
- **Flow Matching & Diff2Flow:** Schusterbauer, J., Gui, M., Fundel, F., & Ommer, B. (2025). *Diff2Flow: Training Flow Matching Models via Diffusion Model Alignment*. CVPR 2025.
- **LPL en Latentes:** *Boosting Latent Diffusion with Perceptual Objectives*. ICLR 2025.

Parte 2: Vision Transformers (ViT) y Evolución 2026

El segundo conjunto de ecuaciones describe la base de los **Vision Transformers (ViT)**, que para 2026 se han convertido en el estándar absoluto (*backbone* por defecto) superando a las CNNs en detección, segmentación y análisis de profundidad.

2.1 Adaptación Visual Base

1. **De Tokens a Parches:** Una imagen se divide en parches y se aplanan en vectores (X). Las arquitecturas de 2026 han mejorado esto con **Procesamiento Jerárquico** (ej. Swin V3), donde los parches se fusionan en múltiples niveles de abstracción (como la visión humana), reduciendo el costo computacional hasta un 40% para alta resolución.
2. **Posicionamiento (RoPE y Registers):**
 - En lugar de la simple suma $X \leftarrow X + P$, los modelos modernos como **ViT-5** (2026) utilizan *Rotary Positional Embeddings* (RoPE) bidimensionales y "Tokens de Registro" que mitigan los artefactos de atención y mejoran el razonamiento espacial relativo.
3. **Mecanismo de Atención Global Bidireccional:**
 - $S = \frac{QK^T}{\sqrt{d_k}}$; $A = \text{softmax}(S)$ (Se elimina la máscara causal del NLP para ver en todas direcciones).
 - **Innovación Reciente:** *Cross-Scale Token Routing*. Los modelos ahora enrutan la atención dinámicamente, ignorando fondos redundantes y enfocando los cálculos en áreas críticas (texto, objetos), acelerando el procesamiento.

2.2 ViT-5: La Arquitectura Contemporánea (Mid-2020s)

Presentado en 2026, **ViT-5** consolida cinco años de refinamientos tomados de los Grandes Modelos de Lenguaje (LLMs) y los adapta específicamente a la visión.

- **Normalización Estricta:** Incorpora RMSNorm y, crucialmente, **QK-Norm** (normalización directa sobre las Queries y Keys antes de calcular la atención). Esto suaviza el entrenamiento, previniendo los picos de pérdida que afectaban a los ViT originales.
- **Control de Escala (LayerScale):** Estabiliza la optimización en redes muy profundas mediante pesos adaptativos por canal, pero (a diferencia de los LLMs) evita deliberadamente compuertas como SwiGLU, que en visión provocan una sobreerregulación perjudicial.

Citas Académicas (ViT de Vanguardia):

- **ViT Original:** Dosovitskiy, A., et al. (2021). *An Image is Worth 16x16 Words*. ICLR.
- **ViT-5 (Estado del Arte 2026):** Wang, F., Ren, S., Zhang, T., Neskovic, P., Bhattad, A., Xie, C., & Yuille, A. (2026). *ViT-5: Vision Transformers for The Mid-2020s*. arXiv:2602.08071.

Documento compilado a partir de ecuaciones fundamentales, verificadas y actualizadas contra la literatura académica del estado del arte (2025-2026) en Visión Artificial.